

1. (1%) 請說明這次使用的 **model** 架構，包含各層維度及連接方式。

我使用 TA 手把手 code。

前面四層都是 convolutional layer+maxpooling

Conv2d(input channels=1,output channels=32)//(48,48,32)

Maxpool2d(2)//池化層 將圖片長寬縮為 1/2 (24,24,32)

Conv2d(input channels=32,output channels=64)//(24,24,64)

Maxpool2d(2)// (12,12,64)

Conv2d(input channels=64,output channels=128)//(12,12,128)

Maxpool2d(2)// (6,6,128)

Conv2d(input channels=64,output channels=128)//(6,6,128)

Maxpool2d(2)// (3,3,128)

最後兩層 fully connected layer


Linear(input channels=3*3*128, output layers=256)

Relu()

Linear(input channels=256, output layers=7)


輸出 7 個 channel 對應到 7 個 label。

2. (1%) 請附上 **model** 的 training/validation history (loss and accuracy)。



3. (1%) 畫出 **confusion matrix** 分析哪些類別的圖片容易使 **model** 搞混，並簡單說明。

(ref: https://en.wikipedia.org/wiki/Confusion_matrix)



左圖是 **training data** 的 **confusion matrix**，右圖則是基於 **validation data**。


在兩張圖中，**Happy** 的準確度都特別高，從 **raw data** 中會發現該標籤的資料數量較多，加上 **happy** 是這七個標籤當中唯一表現正面能量的臉部表情，兩者都有可能是造成這個現象的原因之一。越接近的情感越容易被誤判：**Disgust** 被誤判的情況下，有很高的機率被誤判為 **angry**，這蠻合理的，當我們厭惡一個人，我們就容易對他生氣；再看看 **sad** 被誤判的情況下，有較高機率會被判為 **neutral**，當我們對一個人感到難過，他做得再多再好，你都覺得無感。

【關於第四及第五題】

可以使用簡單的 **3-layer CNN model [64, 128, 512]** 進行實作。

4. (1%) 畫出 **CNN model** 的 **saliency map**，並簡單討論其現象。

(ref: <https://reurl.cc/Qpjj8b>)



我是採用助教建議的[64,128,512]之 3-layer model。這是從第一層 **convolution layer** 所得到的 **saliency map**，可能由於是第一層的關係，故還是可以很明顯的看到輪廓，大致而言看起來像是原圖反白後的結果。

5. (1%) 畫出最後一層的 **filters** 最容易被哪些 **feature** activate.

(ref: <https://reurl.cc/ZnrgYg>)

6. (3%) Refer to math problem

ML HW3 R06522709 鄭呈毅.

1. Convolution:

a batch of image data with shape $(B, W, H, \text{Input-channels})$
 \downarrow width
 \uparrow height
 Batch size

$\text{Conv2D}(\text{Input-channels}, \text{output-channels}, \text{kernel-size}=(k_1, k_2),$
 $\text{stride}=(s_1, s_2), \text{padding}=(P_1, P_2))$

Shape after convolution layer.

$(B, ((W+2P_1)-k_1)/s_1+1, (H+2P_2-k_2)/s_2+1,$
 output-channels)

2. Batch Normalization:

parameters to be learned: γ, β

$$\mu_B \leftarrow \frac{1}{m} \sum_{i=1}^m x_i \quad // \text{mini-batch mean}$$

$$\sigma_B^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2 \quad // \text{mini-batch variance}$$

$$\hat{x}_i \leftarrow \frac{x_i - \mu_B}{\sigma_B^2 + \epsilon} \quad // \text{normalize}$$

$$y_i \leftarrow \gamma \hat{x}_i + \beta \equiv \text{BN}_{\gamma, \beta}(x_i) \quad // \text{scale and shift.}$$

$$\frac{\partial \mathcal{L}}{\partial \hat{x}_i} = \frac{\partial \mathcal{L}}{\partial y_i} \cdot \gamma$$

$$\frac{\partial \mathcal{L}}{\partial \sigma_B^2} = \sum_{i=1}^m \frac{\partial \mathcal{L}}{\partial \hat{x}_i} \cdot (x_i - \mu_B) \cdot \frac{-1}{2} (\sigma_B^2 + \epsilon)^{-3/2}$$

$$\frac{\partial \mathcal{L}}{\partial \mu_B} = \left(\sum_{i=1}^m \frac{\partial \mathcal{L}}{\partial \hat{x}_i} \cdot \frac{-1}{\sigma_B^2 + \epsilon} \right) + \frac{\partial \mathcal{L}}{\partial \sigma_B^2} \cdot \frac{\sum_{i=1}^m -2(x_i - \mu_B)}{m}$$

$$\frac{\partial \mathcal{L}}{\partial x_i} = \frac{\partial \mathcal{L}}{\partial \hat{x}_i} \cdot \frac{1}{\sigma_B^2 + \epsilon} + \frac{\partial \mathcal{L}}{\partial \sigma_B^2} \cdot \frac{2(x_i - \mu_B)}{m} + \frac{\partial \mathcal{L}}{\partial \mu_B} \cdot \frac{1}{m}$$

$$\frac{\partial \mathcal{L}}{\partial \gamma} = \sum_{i=1}^m \frac{\partial \mathcal{L}}{\partial y_i} \cdot \hat{x}_i$$

$$\frac{\partial \mathcal{L}}{\partial \beta} = \sum_{i=1}^m \frac{\partial \mathcal{L}}{\partial y_i}$$

3. Softmax and Cross Entropy.

$$\text{softmax}(z_t) = \frac{e^{z_t}}{\sum_i e^{z_i}}$$

$$\text{cross-entropy} = L(y, \hat{y}) = -\sum_i y_i \log \hat{y}_i.$$

$$\text{cross-entropy} = L_t(y_t, \hat{y}_t) = -y_t \log \hat{y}_t. \quad (y_t=1).$$

$$\hat{y}_t = \text{softmax}(z_t)$$

$$\text{Derive that } \frac{\partial L_t}{\partial z_t} = \hat{y}_t - y_t.$$

$$\begin{aligned} \frac{\partial \hat{y}_i}{\partial z_i} &= \frac{\partial \left(\frac{e^{z_i}}{\sum_c e^{z_c}} \right)}{\partial z_i} = \frac{e^{z_i} \sum_c - e^{z_i} e^{z_i}}{\sum_c^2} = \frac{e^{z_i}}{\sum_c} \frac{\sum_c - e^{z_i}}{\sum_c} \\ &= \hat{y}_i (1 - \hat{y}_i) \end{aligned}$$

$$\frac{\partial L_t}{\partial z_t} = \frac{\partial (-y_t \log \hat{y}_t)}{\partial z_t}$$

$$= -y_t \cdot \frac{\partial (\log \hat{y}_t)}{\partial z_t}$$

$$= -y_t \cdot \frac{1}{\hat{y}_t} \cdot \hat{y}_t (1 - \hat{y}_t)$$

$$= -y_t (1 - \hat{y}_t) = \hat{y}_t - y_t$$



Scanned with
CamScanner